

職務経歴書

2026年8月24日 現在

余顯漁 (Shem Yu)

シニアAIエンジニア @ Cookpad | GenAI、AIエージェント、MLOps | 東京

AI / ML Platform (LY ly00161)

shauns4y@gmail.com | +886 953 240 855 | 台北、台湾 | github.com/ShemYu | LinkedIn

職務要約

本番環境のエージェント、RAG基盤、共有GenAIインフラの構築に6年従事してきたApplied AIエンジニア。現在はCookpadにて、エージェント評価・推論アーキテクチャ・信頼性を軸にマルチモーダルなコーチングエージェントを開発。以前は金融サービス領域で、本番GenAIシステムを届けるMLEチームをリード。

活かせる経験・スキル

クラウド / インフラ：AWS (EC2, Fargate, Lambda, Route53)、Databricks、Distributed Systems、High-Availability Analytics、AI Gateway、Guardrails、MCP Protocol

MLOps / デプロイ：Databricks、MLflow、Docker、CI/CD (Azure DevOps)、Kubernetes、AWS SageMaker、AWS Lambda

プログラミング / MLフレームワーク：Python (エキスパート)、R (基礎)、C/C++ (使用経験あり)、Hugging Face、FastAPI、GoogleADK、LangChain

生成AI / NLP：Agent System Design、Retrieval-Augmented Generation (RAG)、Large Language Models (LLM)、Prompt Engineering、ASR/TTS、Embedding Databases、Search/Indexing Techniques

データエンジニアリング：AP Data Layer Design、SQL、NoSQL、Data Pipeline Design、ETL、Data Visualization

語学：中国語 (母語)、英語 (限定的な実務)

職務経歴

Cookpad (クックパッド)

2026年2月 ~ 現在

シニアAIエンジニア (東京、日本)

日常をより楽しくするAIを構築。

- 観察、ギャップ推論、コーチング判断を分離した段階的マルチモーダル推論パイプラインを設計し、デバッグ容易性を高め、エージェント各段階への障害伝播を抑制。
- カバレッジ、真実性、一貫性、ターンごとの品質を対象に、バージョン管理された能力ベースのエージェント評価と自動スコアリングを設計。

Cathay Financial Holdings

2022年9月 ~ 2026年1月

機械学習エンジニア、チームリード (台北、台湾)

4名のMLEチームをリードし、AIプロジェクトのデプロイと部門内エージェント開発を統括。

- GenAIインフラ (AI Gateway、Guardrails、MLflow) を設計・構築し、社内AIサービスのレイテンシを60%改善。
- FinOpsの実践により、クラウド支出を全体で40%削減。
- FinOpsエージェントを実装し、GPUコストを30%削減。
- DatabricksワークフローとAWSインフラでソリューションをデプロイし、スケーラブルでセキュアな運用を確保。

Wisers Information Limited

2020年11月 ~ 2022年5月

シニアAIプラットフォームエンジニア

新旧プロジェクトを横断し、統一プラットフォームへの移行を可能にする、チーム横断のAIソリューション統合を支援。

- 標準MLプロジェクトテンプレート (AI Cloud Platformテンプレート：FastAPI、CI/CD、Kubernetes) を整備。デプロイ期間を2週間から3日へ短縮し、30以上のプロジェクトで採用。
- NLP向けPythonライブラリ (UAP Common Library) を実装。社内採用率70%、コードカバレッジ90%以上で、AI開発者の生産性と信頼性を向上。
- SphinxとCIによるドキュメントパイプライン自動化を主導し、オンボーディング効率とプラットフォームの使いやすさを向上。

ETLパイプラインとデータ収集の維持を支援し、変動する事業環境でも安定した分析を確保。

- 統計モデリング（FP-Growth、K-means、4クラスタ）で顧客注文データを分析し、マーケティングとセグメンテーションを支援。

学歴

銘傳大学

修士（コンピュータサイエンス・情報工学）

GPA 3.82

2017年6月 ～ 2019年7月

- 修士論文：Yu, H. Y. and Lee, Y. S. “The Portfolio Analysis of the Key Fans for FB fan pages,” 2019.
- 研究室を代表して研究成果を2回発表し、うち1回は3位入賞。

銘傳大学

学士（コンピュータサイエンス・情報工学）

2012年6月 ～ 2016年6月

資格

AWS Certified Cloud Practitioner、Amazon Web Services

2024年5月

AWS Certified Machine Learning - Specialty、Amazon Web Services

2024年10月